

Raspodijeljeni sustavi (RS - 273470)

Raspodijeljeni sustavi



Nositelj: doc. dr. sc. Nikola Tanković

Asistent: Luka Blašković, mag. inf.

Ustanova: Sveučilište Jurja Dobrile u Puli, Fakultet informatike u Puli



Fakultet informatike u Puli

(2) Napredniji Python koncepti

U ovoj ćemo se skripti usredotočiti na naprednije značajke programskog jezika Python koje će vam olakšati i ubrzati izradu rješenja unutar ovog kolegija, ali i unaprijediti vaše opće razumijevanje i rad s jezikom. Obradit ćemo teme kao što su anonimne (lambda) funkcije, funkcije višeg reda, korištenje paketa i modula, *comprehension* sintaksa za brzo stvaranje struktura podataka te osnove objektno orijentiranog programiranja kroz rad s klasama i objektima.



UP! Posljednje ažurirano: 13.9.2026.

Sadržaj

- [Raspodijeljeni sustavi \(RS - 273470\)](#)
- [\(2\) Napredniji Python koncepti](#)
 - [Sadržaj](#)
- [1. Lambda funkcije](#)
 - [1.1 Lambda funkcije kao argumenti drugih funkcija](#)
 - [1.2 Funkcije višeg reda](#)
 - [1.2.1 Funkcija `map`](#)
 - [1.2.2 Funkcija `filter`](#)
 - [1.2.3 Funkcije `any` i `all`](#)
 - [1.2.4 Funkcija `reduce`](#)
- [2. Izgradnja struktura kroz `comprehension` sintaksu](#)
 - [2.1 List comprehension](#)

- [2.2 Dictionary comprehension](#)
- [3. Zadaci za vježbu - lambda izrazi, funkcije višeg reda i *comprehension* sintaksa](#)
 - [Zadatak 1: Lambda izrazi](#)
 - [Zadatak 2: Funkcije višeg reda](#)
 - [Zadatak 3: Comprehension sintaksa](#)
- [4. Klase i objekti](#)
 - [4.1 Definiranje klase i stvaranje objekta](#)
 - [4.2 Konstruktor klase](#)
 - [4.3 Metode klase](#)
 - [4.4 Nasljeđivanje](#)
- [5. Moduli i paketi](#)
 - [5.1 Moduli](#)
 - [5.1.1 Ugrađeni moduli](#)
 - [5.2 Paketi](#)
- [6. Zadaci za vježbu - Klase, objekti, moduli i paketi](#)
 - [Zadatak 4: Klase i objekti](#)
 - [Zadatak 5: Moduli i paketi](#)

1. Lambda funkcije

Lambda funkcije su anonimne funkcije koje se najčešće koriste za kratke, jednostavne operacije definirane u jednoj liniji koda. Naziv „anonimne“ dolazi od toga što im se ne dodjeljuje ime, za razliku od standardnih funkcija. Mogu primiti proizvoljan broj argumenata, ali sadrže samo jedan izraz (eng. expression).

Sintaksa:

```
lambda arguments : expression
```

Primjer: Klasičnu funkciju za kvadriranje broja možemo napisati ovako:

```
def kvadriraj(x):  
    return x ** 2  
  
print(kvadriraj(5)) # 25
```

Kod lambda funkcije, potrebno je izbaciti ključnu riječ `def` i ime funkcije, a umjesto toga koristimo ključnu riječ `lambda`.

Primjer: Lambda funkcija (izraz) za kvadriranje broja:

```
lambda x: x ** 2  
print((lambda x: x ** 2)(5)) # 25
```

Lambda funkcije se mogu pohranjivati u varijable, a zatim pozivati preko tih varijabli, kao i obične funkcije:

```
kvadriraj = lambda x: x ** 2

print(kvadriraj(5)) # 25
```

Lambda funkcije mogu primiti više argumenata:

```
zbroji = lambda x, y: x + y

print(zbroji(5, 3)) # 8

zbroji_kvadrata = lambda x, y: x ** 2 + y ** 2

print(zbroji_kvadrata(3, 4)) # 25
```

Ali i ne moraju primiti niti jedan argument:

Sljedeći primjer nema smisla jer je moguće samo pohraniti vrijednost "Pozdrav!" u varijablu i ispisati je, ali je koristan za dokaz lambde koje ne primaju argumente:

```
pozdrav = lambda: "Pozdrav!"

print(pozdrav()) # Pozdrav!
```

U lambda funkcijama, kao i običnim, možemo postaviti zadane vrijednosti (*eng.* default values) za argumente:

```
pozdrav = lambda ime="Ivan": f"Pozdrav, {ime}!" # koristimo f-string za formatiranje stringa

print(pozdrav()) # Pozdrav, Ivan!
print(pozdrav("Marko")) # Pozdrav, Marko!
```

Pa i više njih:

```
circle_area = lambda r=1, pi=3.14: pi * r ** 2

print(circle_area()) # 3.14
print(circle_area(2)) # 12.56
```

Ako lambda funkcija ima više argumenata, **argumente s zadanim vrijednostima uvijek postavljamo na kraj.**

Ovo pravilo vrijedi i za obične funkcije:

```
def multiplier_wrong(x=2, factor): # Greška!
    return x * factor # Greška!

multiplier_wrong = lambda x=2, factor: x * factor # Greška!

multiplier = lambda x, factor = 2: x * factor # Ispravno!

print(multiplier(5)) # 10
print(multiplier(5, 3)) # 15
```

Naravno, kao i obične funkcije, lambda funkcije je moguće koristiti sa svim tipovima podataka, uključujući i strukture podataka:

```
velika_slova = lambda niz: niz.upper()

print(velika_slova("pozdrav")) # POZDRAV

lista=[1,2,3,4,5]
print(lambda lst: sum(lst)(lista)) # 15
```

1.1 Lambda funkcije kao argumenti drugih funkcija

Prava snaga lambda funkcija dolazi do izražaja kada ih koristimo kao argumente drugih funkcija. Na taj način stvaramo **funkcije višeg reda** - funkcije koje primaju druge funkcije kao argumente ili vraćaju druge funkcije kao rezultat.

Dodatno, moguće ih je koristiti kao anonimne funkcije unutar drugih funkcija, iz opet istog razloga, kako bi se izbjeglo definiranje dodatnih funkcija koje se koriste samo jednom.

Primjer: Želimo napisati funkciju koja će primati **listu brojeva** i **funkciju koja će se primijeniti na svaki element** liste. To možemo napraviti ovako:

```
def primijeni_na_sve(lista, funkcija):
    rezultat = []
    for element in lista:
        rezultat.append(funkcija(element)) # u novu listu dodajemo rezultate funkcije
    primijenjene na svaki element
    return rezultat
```

Što je ovdje **funkcija**? Što god želimo i definiramo kao funkciju. Primjerice, želimo kvadrirati svaki element liste, za to možemo definirati malu anonimnu lambda funkciju:

```
lambda x: x ** 2 # Čitaj: za svaki element x vraća x na kvadrat; za svaki element x izvrši
izraz x ** 2
```

- prosljedimo je kao argument **funkcija** funkciji **primijeni_na_sve**:

```
print(primijeni_na_sve([1, 2, 3, 4], lambda x: x ** 2)) # [1, 4, 9, 16]
```

- ili želimo primijeniti funkciju koja potencira vrijednost na treću potenciju:

```
print(primijeni_na_sve([1, 2, 3, 4], lambda x: x ** 3)) # [1, 8, 27, 64]
```

- funkciju je moguće pohraniti i u varijablu te potom proslijediti:

```
uvecaj_zaj_5 = lambda broj: broj + 5
```

```
print(primijeni_na_sve([1, 2, 3, 4], uvecaj_zaj_5)) # [6, 7, 8, 9]
```

Lambda funkcija (lambda izraz) može biti i povratna vrijednost neke funkcije. Primjerice, funkcija `kvadriraj` vraća lambda funkciju koja kvadrira broj:

```
def kvadriraj():  
    return lambda x: x ** 2  
  
kvadriraj_broj = kvadriraj()  
  
print(kvadriraj_broj(5)) # 25
```

OK, na tom primjeru nema puno smisla. Međutim, možemo definirati **funkciju** koja će vraćati **funkciju** koja će primiti broj kao argument i množiti ga s nekim faktorom:

Primjer:

```
def mnozi_sa_faktorom(faktor): # Funkcija koja vraća lambda funkciju  
    return lambda x: x * faktor # Lambda funkcija množi interni argument "x" s argumentom  
    vanjske funkcije "faktor"  
  
mnozi_sa_5 = mnozi_sa_faktorom(5) # ovo je ekvivalentno: mnozi_sa_5 = lambda x: x * 5  
  
print(mnozi_sa_5(3)) # 15
```

Kako ovo radi?

1. Funkcija `mnozi_sa_faktorom` prima `faktor` kao argument i vraća lambda funkciju koja prima `x` kao argument i množi ga s `faktor`.
2. U varijablu `mnozi_sa_5` pohranjujemo rezultat poziva funkcije `mnozi_sa_faktorom` s argumentom `5`. Rezultat poziva te funkcije je lambda funkcija koja množi broj s `5`.
3. Pozivamo funkciju `mnozi_sa_5` s argumentom `3` i dobivamo rezultat `15`.

Ako želimo, možemo definirati i uvjete unutar izraza lambda funkcije:

Sintaksa:

```
lambda arguments: expression if condition else expression
```

Primjer: Želimo kvadrirati broj samo ako je paran:

```
kvadriraj_parne = lambda x: x ** 2 if x % 2 == 0 else x
```

- ili želimo vratiti duljinu znakovnog niza ako je duljina veća od 5, inače vraćamo sam znakovni niz:

```
dulji_od_5 = lambda niz: len(niz) if len(niz) > 5 else niz
```

- ili želimo vratiti "paran" ako je broj paran, inače "neparan":

```
paran_neparan = lambda x: "paran" if x % 2 == 0 else "neparan"
```

1.2 Funkcije višeg reda

Funkcije višeg reda (eng. *Higher-order functions*) su **funkcije koje primaju druge funkcije kao argumente** ili **vraćaju druge funkcije kao rezultat**.

Lambda funkcije su korisne jer nam omogućuju pisanje funkcija višeg reda bez potrebe za definiranjem dodatnih funkcija koje se koriste samo jednom.

Primjerice, funkcija `primijeni_na_sve` iz prethodnog primjera je funkcija višeg reda jer prima drugu funkciju kao argument.

Funkcije višeg reda su korisne jer omogućuju pisanje modularnog koda, tj. koda koji je podijeljen u manje, samostalne dijelove koji obavljaju specifične zadatke.

- Ono što ćemo vjerojatno najčešće raditi, je **koristiti lambda funkcije kao argumente ugrađenim funkcijama višeg reda**, kao što su `map`, `filter`, `reduce`, `sort` itd.

1.2.1 Funkcija `map`

Funkcija `map` prima **funkciju** i **iterabilni objekt** (npr. listu) i primjenjuje tu funkciju na svaki element tog objekta. Povratna vrijednost je **map objekt** koji se može pretvoriti u listu, tuple ili neki drugi iterabilni objekt.

Sintaksa:

```
map(function, iterables)
```

Primjer: Želimo kvadrirati svaki element liste:

```

lista = [1, 2, 3, 4]

kvadriraj = lambda x: x ** 2

kvadrirana_lista = list(map(kvadriraj, lista)) # map vraća map objekt, zato koristimo list()
za pretvaranje u listu

# ili kraće:

kvadrirana_lista = list(map(lambda x: x ** 2, lista))

```

Kako ovo radi?

1. `map` je funkcija višeg reda koja prima lambda funkciju koja kvadrira broj (`lambda x: x ** 2`) i listu `[1, 2, 3, 4]`.
2. `map` primjenjuje tu funkciju na svaki element liste i vraća map objekt.
3. `list` pretvara map objekt u listu.

Što ako želimo izvući određeni ključ iz neke liste rječnika i spremiti ga u novu listu?

Primjer: Imamo listu studenata s imenom, prezimenom i JMBAG-om. Želimo izvući samo JMBAG-ove:

Kako bismo ovo učinili "ručno"? Bez lambda funkcija i funkcija višeg reda (`map`)?

```

studenti = [
    {"ime": "Ivan", "prezime": "Ivić", "jmbag": "0303077889"},
    {"ime": "Marko", "prezime": "Marković", "jmbag": "0303099878"},
    {"ime": "Ana", "prezime": "Anić", "jmbag": "0303088777"}
]

jmbagovi = []

for student in studenti:
    jmbagovi.append(student["jmbag"])

print(jmbagovi) # ['0303077889', '0303099878', '0303088777']

```

Kako bismo to učinili koristeći `map` i lambda funkciju?

```

jmbagovi = list(map(lambda student: student["jmbag"], studenti)) # student je svaki pojedini
element (rječnik) liste studenti

print(jmbagovi) # ['0303077889', '0303099878', '0303088777']

```

Kako ovo radi?

- `map` prima lambda funkciju: `lambda student: student["jmbag"]` i listu `studenti`.
- Lambda funkcija prima svaki pojedini element liste `studenti` (rječnik) i vraća vrijednost ključa `"jmbag"`.
- `map` vraća map objekt.

- `list` pretvara map objekt u listu.

`map` funkcija je korisna jer omogućuje brzu i jednostavnu transformaciju podataka. Može primiti proizvoljni broj iterabilnih objekata, ali mora primiti **točno jednu funkciju**.

Funkcije višeg reda, općenito, ne moraju primiti funkciju u obliku lambda funkcije. Možemo koristiti i običnu referencu na funkciju:

```
def zbroji(a, b):  
    return a + b  
  
print(list(map(zbroji, [1, 2, 3], [4, 5, 6])))  
# ili kraće:  
print(list(map(lambda a, b: a + b, [1, 2, 3], [4, 5, 6])))
```

Ovdje koristimo funkciju `zbroji` koja prima dva argumenta i zbraja ih. `map` prima tu funkciju i dvije liste `[1, 2, 3]` i `[4, 5, 6]` i zbraja elemente na istim pozicijama.

Što će ispisati gornji primjer?

```
[5, 7, 9]
```

1.2.2 Funkcija `filter`

Funkcija `filter` prima funkciju koja vraća `True` ili `False` i **iterabilni objekt**. Vraća **filter objekt** koji se može pretvoriti u listu, tuple ili neki drugi iterabilni objekt.

Ova funkcija će filtrirati elemente iterabilnog objekta prema rezultatu funkcije (**predikata**) koja vraća `True` ili `False`.

Sintaksa:

```
filter(function, iterables)
```

Primjerice: Želimo filtrirati samo parne brojeve iz liste:

Prvo kako bismo to učinili "ručno":

```
lista = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]  
  
parni = []  
  
for broj in lista:  
    if broj % 2 == 0:  
        parni.append(broj)  
  
print(parni) # [2, 4, 6, 8, 10]
```

- ili koristeći `filter` i lambda funkciju:

```
parni = list(filter(lambda x: x % 2 == 0, lista))
```

Naravno možemo kombinirati i različite strukture podataka:

```
studenti = [
    {"ime": "Ivan", "prezime": "Ivić", "jmbag": "0303077889", "godina_rodenja": 2000},
    {"ime": "Marko", "prezime": "Marković", "jmbag": "0303099878", "godina_rodenja": 1999},
    {"ime": "Ana", "prezime": "Anić", "jmbag": "0303088777", "godina_rodenja": 2003},
    {"ime": "Petra", "prezime": "Petrić", "jmbag": "0303088777", "godina_rodenja": 2001}
]

rodeni_prije_2000 = list(filter(lambda student: student["godina_rodenja"] < 2000, studenti))
```

Kako bismo ovo zapisali “ručno”?

```
rodeni_prije_2000 = []

for student in studenti:
    if student["godina_rodenja"] < 2000:
        rodeni_prije_2000.append(student)

print(rodeni_prije_2000) # [{'ime': 'Marko', 'prezime': 'Marković', 'jmbag': '0303099878',
'godina_rodenja': 1999}]
```

Uočite prednosti korištenja funkcija višeg reda i lambda funkcija. Operacije za koje nam treba 4-5 linija koda, u pravilu možemo zapisati u jednoj liniji.

Funkcija `filter` je korisna jer omogućuje brzu i jednostavnu filtraciju podataka. Može primiti proizvoljni broj iterabilnih objekata, ali mora primiti **točno jednu funkciju**.

1.2.3 Funkcije `any` i `all`

Funkcije `any` i `all` su također funkcije višeg reda koje primaju iterabilni objekt i vraćaju `True` ili `False`.

- `any` vraća `True` ako je bilo koji (barem jedan) element iterabilnog objekta istinit, inače vraća `False`.
- `all` vraća `True` ako su svi elementi iterabilnog objekta istiniti, inače vraća `False`.

Primjer: Korištenje funkcije `any`:

```
print(any([False, False, True])) # True (jer je barem jedan element True)

print(any([False, False, False])) # False (jer niti jedan element nije True)
```

Primjer: Korištenje funkcije `all`:

```
print(all([True, True, True])) # True (jer su svi elementi True)

print(all([True, False, True])) # False (jer nisu svi elementi True)
```

Kako koristiti ove funkcije s lambda funkcijama?

Recimo da želimo provjeriti jesu li svi brojevi u listi parni. Idemo prvo ručno:

```
def svi_parni(lista):
    for broj in lista:
        if broj % 2 != 0:
            return False
    return True

print(svi_parni([2, 4, 6, 8])) # True
print(svi_parni([2, 4, 6, 7])) # False
```

- ili koristeći `all`, `map` i lambda funkciju:

```
print(all(map(lambda x: x % 2 == 0, [2, 4, 6, 8]))) # True
print(all(map(lambda x: x % 2 == 0, [2, 4, 6, 7]))) # False
```

Kako ovo radi?

1. `map` prima lambda funkciju: `lambda x: x % 2 == 0` i listu `[2, 4, 6, 8]`.
2. `map` primjenjuje tu funkciju na svaki element liste
3. lista sad postaje `[True, True, True, True]`
4. `all` provjerava jesu li svi elementi liste `True` i vraća `True` jer jesu. `all([True, True, True, True])`

Pogledajmo još jedan primjer, gdje želimo provjeriti jesu li svi putnici uplatili aranžman:

```
putnici = [
    {"ime": "Ivan", "prezime": "Ivić", "uplata": True},
    {"ime": "Marko", "prezime": "Marković", "uplata": True},
    {"ime": "Ana", "prezime": "Anić", "uplata": False}
]

print(all(map(lambda putnik: putnik["uplata"], putnici))) # False
```

- ili ručno:

```
def svi_uplatili(putnici):
    for putnik in putnici:
        if not putnik["uplata"]:
            return False
    return True

print(svi_uplatili(putnici)) # False
```

Sličnih funkcija višeg reda ima još mnogo, primjerice `sorted`, `reduce`, `zip` itd. Korisno je istražiti ih i koristiti u praksi jer će vam uvelike ubrzati i olakšati rad.

1.2.4 Funkcija `reduce`

Funkcija `reduce` se koristi za **smanjivanje** (redukciju) iterabilnog objekta na jednu vrijednost primjenom funkcije na parove elemenata. Ova funkcija nije ugrađena u Python 3, već se nalazi u modulu `functools`, pa je potrebno prvo je učitati.

Sintaksa:

```
from functools import reduce # učitavanje funkcije iz modula functools
reduce(function, iterable)

# ili sa zadanim početnom vrijednosti/vrijednostima
reduce(function, iterable, initializer) # gdje je initializer opcionalna početna vrijednost
```

Funkcija `reduce` prima funkciju `function` koja očekuje 2 argumenta i iterabilni objekt `iterable`. Funkcija se primjenjuje na prvi par elemenata iz iterabilnog objekta, zatim se rezultat te primjene koristi kao prvi argument za sljedeći element iz iterabilnog objekta, i tako dalje, sve dok se ne obradi cijeli iterabilni objekt.

Ovo se često koristi za raznu agregaciju podataka, aplikaciju kompleksne logike za redukciju i druge transformacije.

Pokazat ćemo najjednostavniji primjer - za zbrajanje svih brojeva u listi:

```
from functools import reduce

brojevi = [1, 2, 3, 4, 5]

zbroj = reduce(lambda x, y: x + y, brojevi)

print(zbroj) # 15
```

Ovo nije uobičajeno raditi u Pythonu obzirom da imamo ugrađene funkcije, poput `sum(iterable)`, `max(iterable)`, `min(iterable)`, `len(iterable)`, `any(iterable)`, `all(iterable)` itd. koje su optimizirane i konceptualno se temelje na redukciji.

Primjer: Recimo da želimo pronaći maksimalni broj u listi:

```
from functools import reduce

brojevi = [3, 1, 4, 1, 5, 9, 2, 6, 5, 3, 5]
maksimalni = reduce(lambda x, y: x if x > y else y, brojevi)
print(maksimalni) # 9
```

Za kompleksnije slučajeve često se koriste `reduce-like` funkcije iz raznih drugih biblioteka, kao što su `statistics`, `numpy`, `pandas` itd. Preporuka je koristiti te biblioteke umjesto vlastite implementacije, obzirom da su optimizirane i robustno testirane.

Ipak, `reduce` je koristan za razumijevanje koncepta funkcija višeg reda i primjene lambda funkcija.

2. Izgradnja struktura kroz `comprehension` sintaksu

`Comprehension` sintaksa je jedan od najmoćnijih alata u Pythonu. Omogućuje nam brzu i jednostavnu izgradnju struktura podataka, kao što su liste, rječnici i skupovi bez da koristimo višelinijnske petlje ili funkcije višeg reda poput `map`, `filter`, `any`, `all` itd. (iako se one i dalje mogu koristiti unutar `comprehension` sintakse).

Ova sintaksa pruža čitljiv i mnogo kraći način za **izgradnju kolekcija** u usporedbi s “klasičnim” pristupom korištenjem petlji.

Postoje 4 glavne vrste `comprehension` sintakse:

1. **List comprehension** (izgradnja liste)
2. **Dictionary comprehension** (izgradnja rječnika)
3. **Set comprehension** (izgradnja skupa)
4. **Generator comprehension** (izgradnja generatora)

Nećemo se baviti generatorima, ali ćemo proučiti prve tri vrste.

Najčešće ćemo koristiti ***list comprehension***, ali je korisno znati i ostale vrste.

2.1 List comprehension

Krenimo jednostavno: želimo izgraditi **listu kvadrata brojeva od 1 do 10**.

U svim sljedećim primjerima prikazat će se rješenje na **klasičan način** i način ***comprehension sintaksom***.

Klasičan način:

```
kvadrati = []

for i in range(1, 11):
    kvadrati.append(i ** 2)

print(kvadrati) # [1, 4, 9, 16, 25, 36, 49, 64, 81, 100]
```

Rekli smo da ovo možemo skratiti i korištenjem `map` funkcije višeg reda:

```
kvadrati = list(map(lambda x: x ** 2, range(1, 11)))

print(kvadrati) # [1, 4, 9, 16, 25, 36, 49, 64, 81, 100]
```

Ali i korištenjem ***list comprehension*** sintakse:

```
kvadrati = [x ** 2 for x in range(1, 11)]

print(kvadrati) # [1, 4, 9, 16, 25, 36, 49, 64, 81, 100]
```

Idemo usporediti sve tri metode:

1. Klasičan način:

- 3 linije koda ukupno:
 - 1 linija za inicijalizaciju liste
 - 1 linija za petlju
 - 1 linija za dodavanje elementa u listu

2. Korištenjem `map` funkcije:

- 1 linija koda ukupno:
 - `map` funkcija prima lambda funkciju i `range` objekt
 - lambda funkcija kvadrira broj, a `range` objekt vraća listu brojeva od 1 do 10
 - `list` pretvara `map` objekt u listu

3. Korištenjem *list comprehension* sintakse:

- 1 linija koda ukupno:
 - poznata sintaksa `for` petlje koja iterira kroz `range` objekt (listu brojeva od 1 do 10)
 - ispred se dodaje izraz koji se izvršava za svaki element (`x ** 2`)
 - rezultat se dodaje u listu što je definirano uglatim zagradama `[...]`

Osnovna sintaksa (*list comprehension*)

```
[expression for element in iterable]
```

Gdje je:

- `expression` izraz koji se izvršava za svaki element
- `element` varijabla koja predstavlja trenutni element
- `iterable` iterabilni objekt (npr. lista, skup, rječnik, generator), u ovom slučaju je lista brojeva od 1 do 10

Recimo da imamo listu znakovnih nizova gdje želimo **izgraditi listu duljina tih nizova**:

Klasičan način:

```
nizovi = ["jabuka", "kruška", "banana", "naranča"]

duljine = []

for niz in nizovi:
    duljine.append(len(niz))

print(duljine) # [6, 6, 6, 7]
```

List comprehension:

```
duljine = [len(niz) for niz in nizovi]

print(duljine) # [6, 6, 6, 7]
```

Ovdje je `len(niz)` izraz koji se izvršava za svaki element `niz` u listi `nizovi`.

Idemo dalje, možemo nadograditi sintaksu *list comprehensiona* dodavanjem **if** uvjeta.

Kako izgraditi listu kvadrata brojeva od 1 do 10, ali **samo za neparne brojeve**:

Klasičan način:

```
kvadrati_neparnih = []

for i in range(1, 11):
    if i % 2 != 0:
        kvadrati_neparnih.append(i ** 2)

print(kvadrati_neparnih) # [1, 9, 25, 49, 81]
```

List comprehension:

```
kvadrati_neparnih = [x ** 2 for x in range(1, 11) if x % 2 != 0] # uvjet se dodaje na kraj
```

Pomalo je neuobičajeno, ali ove izraze želimo čitati slično kao što bismo ih čitali običnim jezikom:

- “kvadrat broja `x` za svaki `x` u rasponu od 1 do 10 ako je `x` neparni broj”

Međutim, prilikom programiranja često ćemo pisati ove izraze **(1) počevši od petlje**, **(2) zatim izraza** i **(3) uvjeta na kraju**, slično kao što bismo kodirali na klasičan način.

Sintaksa s if uvjetom:

```
[expression for element in iterable if condition]
```

Primjer iznad praktično je “graditi” na sljedeći način:

1. Prvo definiramo `for` petlju koja prolazi kroz sve brojeve od 1 do 10, a izraz neka bude samo taj broj `x`

```
[x for x in range(1, 11)] # [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
```

2. Zatim želimo kao izraz kvadrat brojeva, pa mijenjamo u `x ** 2`

```
[x ** 2 for x in range(1, 11)] # [1, 4, 9, 16, 25, 36, 49, 64, 81, 100]
```

3. Na kraju dodajemo uvjet `if x % 2 != 0` i to nakon `for` petlje

```
[x ** 2 for x in range(1, 11) if x % 2 != 0] # [1, 9, 25, 49, 81]
```

Kako ovo koristiti sa strukturama? Imamo listu rječnika gdje želimo izgraditi **listu imena studenata** koji su rođeni prije 1999. godine:

```
studenti = [
    {"ime": "Ivan", "prezime": "Ivić", "godina_rodenja": 2000},
    {"ime": "Marko", "prezime": "Marković", "godina_rodenja": 1990},
    {"ime": "Ana", "prezime": "Anić", "godina_rodenja": 2003},
    {"ime": "Petra", "prezime": "Petrić", "godina_rodenja": 2001}
]
```

Klasičan način:

```
rodeni_prije_1999 = []

for student in studenti:
    if student["godina_rodenja"] < 1999:
        rodeni_prije_1999.append(student["ime"])

print(rodeni_prije_1999) # ['Marko']
```

List comprehension:

```
rodeni_prije_1999 = [student["ime"] for student in studenti if student["godina_rodenja"] < 1999]

print(rodeni_prije_1999) # ['Marko']
```

Moguće je dodati i **else** izraz:

Primjer: Želimo izgraditi listu kvadrata brojeva od 1 do 10, ali **za neparne brojeve kvadrat, a za parne brojeve sam broj**:

Klasičan način:

```
kvadrati_neparnih_a_parne_brojevi = []

for i in range(1, 11):
    if i % 2 != 0:
        kvadrati_neparnih_a_parne_brojevi.append(i ** 2)
    else:
        kvadrati_neparnih_a_parne_brojevi.append(i)

print(kvadrati_neparnih_a_parne_brojevi) # [1, 2, 9, 4, 25, 6, 49, 8, 81, 10]
```

List comprehension:

```
kvadrati_neparnih_a_parne_brojevi = [x ** 2 for x in range(1, 11) if x % 2 != 0 else x]

print(kvadrati_neparnih_a_parne_brojevi) # SyntaxError: invalid syntax (zašto ???)
```

Sintaksa s `if else` izrazom

```
[expression1 if condition else expression2 for element in iterable]
```

- dok smo kod `if` uvjeta imali:

```
[expression for element in iterable if condition]
```

- dakle, moramo prvo definirati `if` izraz, a zatim `else` izraz i to sve ispred `for` petlje:

```
kvadrati_neparnih_a_parne_brojevi = [x ** 2 if x % 2 != 0 else x for x in range(1, 11)] # [1, 2, 9, 4, 25, 6, 49, 8, 81, 10]
```

Comprehension sintaksu možemo koristiti i sa znakovnim nizovima.

Primjer: Imamo listu voća `fruits`:

```
fruits = ["apple", "banana", "cherry", "kiwi", "mango"]
```

Želimo izgraditi listu voća, ali **samo prva tri slova svakog voća**:

Klasičan način:

```
prva_tri_slova = []

for fruit in fruits:
    prva_tri_slova.append(fruit[:3])

print(prva_tri_slova) # ['app', 'ban', 'che', 'kiw', 'man']
```

List comprehension:

```
prva_tri_slova = [fruit[:3] for fruit in fruits]
```

- Ili želimo izgraditi novu listu voća, npr. koja sadrži samo ono voće koje sadrži slovo `a`:

Klasičan način:

```
sa_slovom_a = []

for fruit in fruits:
    if "a" in fruit:
        sa_slovom_a.append(fruit)

print(sa_slovom_a) # ['apple', 'banana', 'mango']
```

List comprehension:

```
sa_slovom_a = [fruit for fruit in fruits if "a" in fruit]
```

Koji će biti sadržaj sljedeće liste?

```
newlist = [x if x != "banana" else "orange" for x in fruits]

print(newlist) # ?
```

▼ Spoiler alert! Odgovor na pitanje

Za svaki element `x` u listi `fruits`, ako je `x` različit od `"banana"`, dodajemo taj element, inače dodajemo `"orange"`.

Rezultat: `['apple', 'orange', 'cherry', 'kiwi', 'mango']`

2.2 Dictionary comprehension

Dictionary comprehension je vrlo sličan *list comprehensionu*, ali umjesto liste, gradimo rječnik kroz *comprehension* sintaksu.

Sintaksa *dictionary comprehensiona* je sljedeća:

```
{key_expression: value_expression for item in iterable if condition}
```

Uočite :

Gdje je:

- `key_expression` izraz koji se izvršava za ključeve
- `value_expression` izraz koji se izvršava za vrijednosti
- `item` varijabla koja predstavlja trenutni element
- `iterable` iterabilni objekt (npr. lista, skup, rječnik, generator)
- `condition` uvjet koji se može dodati (nije obavezan)

Recimo da imamo listu voća `fruits` i želimo izgraditi rječnik gdje su **ključevi voća**, a **vrijednosti duljina tih voća**:

Klasičan način:

```
fruits = ["apple", "banana", "cherry", "kiwi", "mango"]

duljine_voca = {}

for fruit in fruits:
    duljine_voca[fruit] = len(fruit)

print(duljine_voca) # {'apple': 5, 'banana': 6, 'cherry': 6, 'kiwi': 4, 'mango': 5}
```

Dictionary comprehension:

```
duljine_voca = {fruit: len(fruit) for fruit in fruits}

print(duljine_voca) # {'apple': 5, 'banana': 6, 'cherry': 6, 'kiwi': 4, 'mango': 5}
```

Možemo napraviti i rječnik gdje su ključevi i vrijednosti brojevi, a petlja ide od 1 do 5:

Ključevi neka budu brojevi od 1 do 5, a vrijednosti kvadrati tih brojeva:

Klasičan način:

```
kvadrati_brojeva = {}

for i in range(1, 6):
    kvadrati_brojeva[i] = i ** 2

print(kvadrati_brojeva) # {1: 1, 2: 4, 3: 9, 4: 16, 5: 25}
```

Dictionary comprehension:

```
kvadrati_brojeva = {i: i ** 2 for i in range(1, 6)}

print(kvadrati_brojeva) # {1: 1, 2: 4, 3: 9, 4: 16, 5: 25}
```

Moguće je unutar *comprehension* sintakse koristiti vanjske funkcije:

```
def kvadriraj(x):
    return x ** 2

kvadrati_brojeva = {i: kvadriraj(i) for i in range(1, 6)}
```

Ako želimo dodati uvjete, to radimo na kraju na isti način kao i kod *list comprehensiona*:

Primjer: Želimo izgraditi rječnik gdje su ključevi brojevi, a vrijednosti kvadrati tih brojeva, ali **samo za parne brojeve** od 1 do 10:

Klasičan način:

```
kvadrati_parnih = {}

for i in range(1, 11):
    if i % 2 == 0:
        kvadrati_parnih[i] = i ** 2

print(kvadrati_parnih) # {2: 4, 4: 16, 6: 36, 8: 64, 10: 100}
```

Dictionary comprehension:

```
kvadrati_parnih = {i: i ** 2 for i in range(1, 11) if i % 2 == 0}

print(kvadrati_parnih) # {2: 4, 4: 16, 6: 36, 8: 64, 10: 100}
```

Ako dodamo i else izraz, sintaksa je slična kao kod *list comprehensiona*:

Primjer: Izradit ćemo rječnik gdje ćemo za svaki broj kao ključ postaviti taj broj, a vrijednost će biti “paran” ako je broj paran, inače “neparan”:

Klasičan način:

```
paran_neparan = {}

for i in range(1, 11):
    if i % 2 == 0:
        paran_neparan[i] = "paran"
    else:
        paran_neparan[i] = "neparan"

print(paran_neparan) # {1: 'neparan', 2: 'paran', 3: 'neparan', 4: 'paran', 5: 'neparan', 6: 'paran', 7: 'neparan', 8: 'paran', 9: 'neparan', 10: 'paran'}
```

Dictionary comprehension:

```
paran_neparan = {i: "paran" if i % 2 == 0 else "neparan" for i in range(1, 11)}

print(paran_neparan) # {1: 'neparan', 2: 'paran', 3: 'neparan', 4: 'paran', 5: 'neparan', 6: 'paran', 7: 'neparan', 8: 'paran', 9: 'neparan', 10: 'paran'}
```

Sintaksa **set comprehensiona** je vrlo slična *list comprehensionu*, ali umjesto liste, gradimo skup koristeći {} zagrade, bez `key:value` parova. Rijeđe se koristi u usporedbi s list i dictionary varijantama.

Primjer: Set comprehension za kvadrate brojeva od 1 do 10:

```
kvadrati = {x ** 2 for x in range(1, 11)}  
print(kvadrati) # {1, 4, 36, 9, 16, 49, 25, 64, 100, 81}
```

Primjer: Set comprehension za jedinstvene duljine riječi iz liste:

```
rijeci = ["jabuka", "pas", "knjiga", "zvijezda", "prijatelj", "zvuk", "čokolada", "ples",  
"pjesma", "otorinolaringolog"]  
duljine = {len(riječ) for riječ in rijeci} # vrati duljinu svake riječi u skupu jedinstvenih  
rijeci  
print(duljine) # {3, 4, 6, 8, 9, 17} # redoslijed može varirati jer je skup neuređena  
kolekcija
```

3. Zadaci za vježbu - lambda izrazi, funkcije višeg reda i *comprehension* sintaksa

Zadatak 1: Lambda izrazi

Napišite korespondirajuće **lambda** izraze za sljedeće funkcije:

1. Kvadriranje broja:

```
def kvadriraj(x):  
    return x ** 2
```

2. Zbroji pa kvadriraj:

```
def zbroji_pa_kvadriraj(a, b):  
    return (a + b) ** 2
```

3. Kvadriraj duljinu niza:

```
def kvadriraj_duljinu(niz):  
    return len(niz) ** 2
```

4. Pomnoži vrijednost s 5 pa potenciraj na x:

```
def pomnozi_i_potenciraj(x, y):  
    return (y * 5) ** x
```

5. Vrati True ako je broj paran, inače vrati None:

```
def paran_broj(x):  
    if x % 2 == 0:  
        return True  
    else:  
        return None
```

Zadatak 2: Funkcije višeg reda

Definirajte sljedeće izraze korištenjem funkcija višeg reda i lambda izraza:

1. Koristeći funkciju `map`, kvadrirajte duljine svih nizova u listi:

```
nizovi = ["jabuka", "kruška", "banana", "naranča"]  
  
kvadrirane_duljine = ...  
  
print(kvadrirane_duljine) # [36, 36, 36, 49]
```

2. Koristeći funkciju `filter`, filtrirajte samo brojeve koji su veći od 5:

```
brojevi = [1, 21, 33, 45, 2, 2, 1, -32, 9, 10]  
  
veci_od_5 = ...  
  
print(veci_od_5) # [21, 33, 45, 9, 10]
```

3. Koristeći odgovarajuću funkciju višeg reda i lambda izraz (bez *comprehension*), pohranite u varijablu `transform` rezultat kvadriranja svih brojeva u listi gdje rezultat mora biti rječnik gdje su ključevi originalni brojevi, a vrijednosti kvadrati tih brojeva:

```
brojevi = [10, 5, 12, 15, 20]  
  
transform = ...  
  
print(transform) # {10: 100, 5: 25, 12: 144, 15: 225, 20: 400}
```

4. Koristeći funkcije `all` i `map`, provjerite jesu li svi studenti punoljetni:

```

studenti = [
    {"ime": "Ivan", "prezime": "Ivić", "godine": 19},
    {"ime": "Marko", "prezime": "Marković", "godine": 22},
    {"ime": "Ana", "prezime": "Anić", "godine": 21},
    {"ime": "Petra", "prezime": "Petrić", "godine": 13},
    {"ime": "Iva", "prezime": "Ivić", "godine": 17},
    {"ime": "Mate", "prezime": "Matić", "godine": 18}
]

svi_punoljetni = ...

print(svi_punoljetni) # False

```

5. Definirajte varijablu `min_duljina` koja će pohranjivati minimalnu duljinu riječi `int`. Koristeći odgovarajuću funkciju višeg reda i lambda izraz, pohranite u varijablu `duge_rijeci` sve riječi iz liste `rijeci` koje su duže od `min_duljina`:

```

rijeci = ["jabuka", "pas", "knjiga", "zvijezda", "prijatelj", "zvuk", "čokolada", "ples",
"pjesma", "otorinolaringolog"]

min_duljina = input("Unesite minimalnu duljinu riječi: ")

# min_duljina = 7
duge_rijeci = ...

# print(duge_rijeci) # ['zvijezda', 'prijatelj', 'čokolada', 'otorinolaringolog']

```

Zadatak 3: Comprehension sintaksa

1. Koristeći *list comprehension*, izgradite listu parnih kvadrata brojeva od 20 do 50:

```

parni_kvadrati = ...

print(parni_kvadrati) # [400, 484, 576, 676, 784, 900, 1024, 1156, 1296, 1444, 1600, 1764,
1936, 2116, 2304, 2500]

```

2. Koristeći *list comprehension*, izgradite listu duljina svih nizova u listi `rijeci`, ali samo za nizove koji sadrže slovo `a`:

```

rijeci = ["jabuka", "pas", "knjiga", "zvijezda", "prijatelj", "zvuk", "čokolada", "ples",
"pjesma", "otorinolaringolog"]

duljine_sa_slovom_a = ...

print(duljine_sa_slovom_a) # [6, 3, 6, 8, 9, 8, 6, 17]

```

3. Koristeći *list comprehension*, izgradite listu rječnika gdje su ključevi brojevi od 1 do 10, a vrijednosti su kubovi tih brojeva, ali samo za neparne brojeve, za parne brojeve neka vrijednost bude sam broj:

```
kubovi = ...

print(kubovi) # [{1: 1}, {2: 2}, {3: 27}, {4: 4}, {5: 125}, {6: 6}, {7: 343}, {8: 8}, {9: 729}, {10: 10}]
```

4. Koristeći *dictionary comprehension*, izgradite rječnik iteriranjem kroz listu brojeva od 50 do 500 s korakom 50, gdje su ključevi brojevi, a vrijednosti su korijeni tih brojeva zaokruženi na 2 decimale:

```
korijeni = ...

print(korijeni) # {50: 7.07, 100: 10.0, 150: 12.25, 200: 14.14, 250: 15.81, 300: 17.32, 350: 18.71, 400: 20.0, 450: 21.21, 500: 22.36}
```

5. Koristeći *list comprehension*, izgradite listu rječnika gdje su ključevi prezimena studenata, a vrijednosti su zbrojeni bodovi, iz liste `studenti`:

```
studenti = [
    {"ime": "Ivan", "prezime": "Ivić", "bodovi": [12, 23, 53, 64]},
    {"ime": "Marko", "prezime": "Marković", "bodovi": [33, 15, 34, 45]},
    {"ime": "Ana", "prezime": "Anić", "bodovi": [8, 9, 4, 23, 11]},
    {"ime": "Petra", "prezime": "Petrić", "bodovi": [87, 56, 77, 44, 98]},
    {"ime": "Iva", "prezime": "Ivić", "bodovi": [23, 45, 67, 89, 12]},
    {"ime": "Mate", "prezime": "Matić", "bodovi": [75, 34, 56, 78, 23]}
]

zbrojeni_bodovi = ...

print(zbrojeni_bodovi) # {'Ivić': 152}, {'Marković': 127}, {'Anić': 55}, {'Petrić': 362}, {'Ivić': 236}, {'Matić': 266}]
```

6. Koristeći *dictionary comprehension*, izgradite rječnik gdje su ključevi brojevi od 1 do 10, a vrijednosti su liste faktorijela tih brojeva.

```
import math

faktoriijeli = ...

print(faktoriijeli) # {1: [1], 2: [1, 2], 3: [1, 2, 6], 4: [1, 2, 6, 24], 5: [1, 2, 6, 24, 120], 6: [1, 2, 6, 24, 120, 720], 7: [1, 2, 6, 24, 120, 720, 5040], 8: [1, 2, 6, 24, 120, 720, 5040, 40320], 9: [1, 2, 6, 24, 120, 720, 5040, 40320, 362880], 10: [1, 2, 6, 24, 120, 720, 5040, 40320, 362880, 3628800]}
```

4. Klase i objekti

Klase (eng. *Class*) i **objekti** (eng. *Object*) su temeljna paradigma u objektno orijentiranom programiranju.

Klase su šablonski opisi objekata, dok su objekti instance klasa. Izradom nove klase, automatski se stvara novi **tip podataka**.

Slično kao i u JavaScriptu, u Pythonu je gotovo su gotovo svi programski konstrukti ustvari objekti koji sadrže **atribute** (eng. *attribute*) i **metode** (eng. *method*).

Dakle klase možemo zamisliti kao šablone (eng. *blueprint*) za definiranje atributa i metoda objekata.

Klasu definiramo ključnom riječju `class`, a objekt klase stvaramo **pozivom klase kao funkcije**. Ne koristimo `new` ključnu riječ kao u nekim drugim jezicima.

4.1 Definiranje klase i stvaranje objekta

Primjer: Definicija jednostavne (prazne) klase:

```
class Osoba:
    pass
```

I to je to! Definirali smo klasu `Osoba` koja ne sadrži niti jedan atribut ili metodu. Često koristimo `pass` kada želimo definirati praznu klasu koju ćemo kasnije implementirati, nadograditi ili naslijediti.

Klase je uobičajeno imenovati koristeći **PascalCase** stil, gdje svaka riječ počinje velikim slovom.

Objekt stvaramo pozivom klase kao funkcije:

```
osoba = Osoba()

print(osoba) # <__main__.Osoba object > memorijska lokacija objekta
```

Atribute možemo definirati prilikom definicije, navodeći ih kao varijable unutar klase:

```
class Osoba:
    ime = "Ivan"
    prezime = "Ivić"
    godine = 25

osoba = Osoba()

print(osoba.ime) # Ivan
print(osoba.prezime) # Ivić
print(osoba.godine) # 25
```

4.2 Konstruktor klase

Primjer iznad je pogrešan način definiranja klase jer svi objekti klase `Osoba` dijele iste atribute. Samim time, definirano nije šablona već fiksni zapis.

Iz tog razloga, želimo definirati atribute **po instanciranom objektu klase**, a za to nam služi **konstruktor klase**.

Konstruktor (eng. *Constructor*) je posebna metoda koja se koristi za **inicijalizaciju objekta klase**.

Iz tog razloga možemo definirati **konstruktor klase** koji se definira metodom `__init__`. Ova metoda poziva se svaki put prilikom inicijalizacije objekta klase.

Primjer: Nadogradnja klase `Osoba` s konstruktorom:

```
class Osoba:
    def __init__(self, ime, prezime, godine):
        self.ime = ime
        self.prezime = prezime
        self.godine = godine

osoba = Osoba("Ivan", "Ivić", 25)

print(osoba.ime) # Ivan
print(osoba.prezime) # Ivić
print(osoba.godine) # 25

osoba2 = Osoba("Marko", "Marković", 30)

print(osoba2.ime) # Marko
print(osoba2.prezime) # Marković
print(osoba2.godine) # 30
```

Primijetite da smo koristili `self` kao prvi argument metode `__init__`. `self` je ključna riječ i **referenca na trenutni objekt klase** i koristi se za pristupanje atributima i metodama objekta. Bez navođenja `self` kao prvog argumenta, Python će baciti grešku.

```
class Osoba:
    def __init__(ime, prezime, godine): # TypeError: __init__() takes 3 positional arguments
    but 4 were given
        self.ime = ime
        self.prezime = prezime
        self.godine = godine

osoba = Osoba("Maja", "Majić", 30)
```

4.3 Metode klase

Metode klase su funkcije koje se definiraju unutar klase i koriste se za izvršavanje određenih operacija **na objektima klase**.

Kada definiramo metode, možemo pristupati vrijednostima atributa objekta pomoću `self` reference.

Primjer: Definiranje metode `pozdrav` unutar klase:

```
class Osoba:
    def __init__(self, ime, prezime, godine):
        self.ime = ime
        self.prezime = prezime
        self.godine = godine

    def pozdrav(self):
        return f"Pozdrav, ja sam {self.ime} {self.prezime} i imam {self.godine} godina."
```

Poziv metode:

```
osoba = Osoba("Snješka", "Snježanić", 25)

print(osoba.pozdrav()) # Pozdrav, ja sam Snješka Snježanić i imam 25 godina.

print(pozdrav(osoba)) # oprez, česta greška! Metode pozivamo nad objektima, ovo je primjer
# poziva globalne funkcije koja prima objekt kao argument
```

Metode mogu biti bilo što, od jednostavnih operacija do složenih lambda izraza ili izraza koji pozivaju vanjske funkcije ili unutarnje metode.

Osim `self` reference, i nizanja mogućih argumenata, moguće je definirati i specijalne `*args` i `**kwargs` argumente:

`*args` - omogućuje nam prosljeđivanje varijabilnog broja nenazvanih argumenata metodi.

Primjer:

```
class Zbroj:
    def zbroji(self, *args): # metoda će prihvatiti varijabilan broj argumenata
        return sum(args)

zbroj_objekt = Zbroj()
print(zbroj_objekt.zbroji(1, 2, 3)) # 6
print(zbroj_objekt.zbroji(10, 20, 30, 40, 50)) # 150
```

`**kwargs` - omogućuje nam prosljeđivanje varijabilnog broja nazvanih argumenata (ključ-vrijednost parova) metodi.

Primjer:

```

class Ispis:
    def ispisi_kljuc_vrijednost(self, **kwargs): # metoda će prihvatiti varijabilan broj
nazvanih argumenata
        for key, value in kwargs.items():
            print(f"{key}: {value}")
ispis_objekt = Ispis()
ispis_objekt.ispisi_kljuc_vrijednost(ime="Ana", prezime="Anić", godine=22)
# Ispis:
# ime: Ana
# prezime: Anić
# godine: 22

```

Napomena: Ova pravila ne vrijede samo za metode, već i obične funkcije definirane van klase, ali i za konstruktore klase.

4.4 Nasljeđivanje

Nasljeđivanje (eng. *Inheritance*) je ključna paradigma u objektno orijentiranom programiranju. Omogućuje nam **definiranje novih klasa koje nasljeđuju atribute i metode od postojećih klasa**.

Klasa koja nasljeđuje zove se **podklasa** (eng. *subclass*), a klasa koja se nasljeđuje zove se **nadklasa** (eng. *superclass*).

Prilikom definiranja podklase, navodimo nadklasu u zagradama, a koristeći `super()` funkciju možemo naslijediti sve atribute i metode nadklase.

Primjer nasljeđivanja:

```

class Korisnik:
    def __init__(self, ime, prezime):
        self.ime = ime
        self.prezime = prezime
        self.username = f"{ime.lower()}_{prezime.lower()}"

    def pozdrav(self):
        return f"Pozdrav, ja sam {self.ime} {self.prezime}, moj username je {self.username}."

class Admin(Korisnik):
    def __init__(self, ime, prezime, privilegije):
        super().__init__(ime, prezime) # nasljeđujemo atribute od nadklase
        self.privilegije = privilegije

    def pozdrav(self):
        return f"Pozdrav, ja sam {self.ime} {self.prezime}, moj username je {self.username} i
imam ukupno {len(self.privilegije)} privilegije: {', '.join(self.privilegije)}."

```

Instaciramo objekt klase Admin:

```
root = ["dodavanje_korisnika", "brisanje_korisnika", "dodavanje_postova", "brisanje_postova"]
admin = Admin("Ivan", "Ivić", root)

print(admin.pozdrav()) #Pozdrav, ja sam Ivan Ivić, moj username je ivan_ivić i imam ukupno 4
privilegije: dodavanje_korisnika, brisanje_korisnika, dodavanje_postova, brisanje_postova.
```

Objekte i njihova svojstva možemo brisati pomoću `del` ključne riječi:

```
del admin.privilegije

del admin
```

Napomena: Postoji još mnogo naprednijih Python koncepata vezanih uz klase i objekte, posebice u novijim verzijama Pythona. Objektno-orientirano programiranje nije predmet ovog kolegija, tako da ćemo se zadržati na osnovama.

5. Moduli i paketi

Prilikom izrade Python programa, često je korisno organizirati kod u više datoteka radi bolje čitljivosti (*eng. readability*), lakšeg održavanja (*eng. maintenance*) i ponovne upotrebe (*eng. reusability*). Modul je pojedinačna Python datoteka koja sadrži skup funkcija i klasa dostupnih za korištenje u drugim programima, dok paket predstavlja skup povezanih modula organiziranih u direktorije. Takva struktura koda omogućuje veću modularnost i jednostavnije upravljanje složenijim projektima.

5.1 Moduli

Moduli (*eng. Module*) su Python datoteke koje sadrže definicije funkcija, klasa ili varijabli **koje možemo koristiti u drugim Python datotekama**. Moduli nam omogućuju bolju organizaciju koda i ponovnu upotrebu koda koji se ponavlja i potrebno ga je koristiti u više datoteka.

Module možemo učitati u Python skriptu koristeći ključnu riječ `import`, a definiramo ih u vanjskim datotekama s ekstenzijom `.py`.

Primjer modula:

```
# greetings.py

def pozdrav(ime):
    return f"Pozdrav, {ime}!"
```

Učitavanje modula u glavnoj skripti:

```
# main.py
import greetings

print(greetings.pozdrav("Marko")) # Pozdrav, Marko!
```

Dakle, u “modulima” možemo definirati i varijable/klase, a zatim ih čitati/pozivati u glavnoj skripti na jednak način.

```
# greetings.py

class Student:
    def __init__(self, ime):
        self.ime = ime

    def pozdrav(self):
        return f"Pozdrav, {self.ime}!"

studenti = ["Ana", "Bojan", "Milka", "Dejan", "Ema"]
```

```
# main.py

import greetings

student = greetings.studenti # ['Ana', 'Bojan', 'Milka', 'Dejan', 'Ema']

student_objekt = greetings.Student("Ema")

print(student_objekt.pozdrav()) # Pozdrav, Ema!
```

Modulima možemo davati proizvoljna imena, ali moraju imati ekstenziju `.py`, kao i klasične Python datoteke.

Moguće je prilikom učitavanja modula koristiti i `as` ključnu riječ za davanje **aliasa** modulu. Ovo je korisno kada imamo modul s dugim imenom ili kada želimo izbjeći konflikte imena.

```
import greetings as g

print(g.pozdrav("Ivan")) # Pozdrav, Ivan!
```

Ako želimo učitati samo određene funkcije iz modula, koristimo `from` ključnu riječ:

- Tada ne moramo navoditi naziv modula prilikom poziva funkcije:

```
from greetings import pozdrav

# pozivamo funkciju bez navođenja imena modula "greetings"
print(pozdrav("Iva")) # Pozdrav, Iva!
```

Možemo definirati više funkcija, a zatim učitati samo one koje želimo:

Definirajmo modul `math_operations.py`:

```
# math_operations.py

def zbroj(a, b):
    return a + b

def oduzimanje(a, b):
    return a - b

def mnozenje(a, b):
    return a * b

def dijeljenje(a, b):
    return a / b

def potenciranje(a, b):
    return a ** b

def korijen(a):
    return a ** 0.5

def kvadrat(a):
    return a ** 2
```

Učitavanje samo dviju funkcija iz modula `math_operations.py`: `zbroj` i `oduzimanje`:

```
from math_operations import zbroj, oduzimanje

print(zbroj(5, 3)) # 8
print(oduzimanje(5, 3)) # 2
```

Ili učitavanje svih funkcija iz modula sa zvjezdicom `*`:

```
from math_operations import *

print(zbroj(5, 3)) # 8
print(oduzimanje(5, 3)) # 2
print(mnozenje(5, 3)) # 15
print(dijeljenje(5, 3)) # 1.6666666666666667
print(potenciranje(5, 3)) # 125
print(korijen(25)) # 5.0
print(kvadrat(5)) # 25
```

Moguće je i učitati sve funkcije iz modula i dodati im alias koristeći `as` ključnu riječ:

```
from math_operations import zbroj as add, oduzimanje as sub

print(add(5, 3)) # 8
print(sub(5, 3)) # 2
```

5.1.1 Ugrađeni moduli

Ugrađenih modula u Pythonu ima mnogo, a neki od najčešće korištenih su:

- `math` - matematičke operacije
- `random` - generiranje slučajnih brojeva
- `datetime` - omogućuje rad s datumima i s vremenom
- `os` - omogućuje interakciju s operacijskim sustavom, npr. manipulaciju datotečnog sustava, environment varijablama, itd.
- `sys` - omogućuje pristup parametrima i funkcijama specifičnim za sustav, kao što su argumenti naredbenog retka, standardni ulaz i izlaz, itd.
- `json` - omogućuje rad s JSON formatom i Python objektima (serijalizacija i deserijalizacija)
- `re` - omogućuje rad s regularnim izrazima (regex)
- `collections` - dodatne kolekcije podataka koje nisu ugrađene u Python, kao što su `namedtuple`, `deque`, `Counter`, `OrderedDict`, itd.
- `itertools` - dodatne funkcije za rad s iterabilnim objektima, kao što su `chain`, `cycle`, `repeat`, `combinations`, `permutations`, itd.
- `functools` - dodatne funkcije za rad s funkcijama višeg reda, kao što su `reduce`, `partial`, `lru_cache`, itd.
- `subprocess` - omogućuje pokretanje novih procesa, povezivanje s njihovim ulazom/izlazom i dobivanje njihovih povratnih kodova.

Primjer: Korištenja nekih ugrađenih modula:

```
import math

print(math.pi) # 3.141592653589793
print(math.sqrt(25)) # 5.0
```

```
import random

print(random.randint(1, 10)) # slučajni broj između 1 i 10
```

```
import datetime

print(datetime.datetime.now()) # 2024-11-09 19:36:41.954767
print(datetime.datetime.now().year) # 2024
```

```
import os

print(os.getcwd()) # /Users/lukablaskovic/Github/FIPU-RS
print(os.listdir()) # ['RS1 - Ponavljanje Pythona', '.DS_Store', 'RS2 - Napredniji Python koncepti', 'README.md', 'RS3 - Asyncio i Aiohttp', '.git']

os.mkdir("nova_mapa") # stvara novu mapu "nova_mapa"
```

Dokumentaciju (index) ugrađenih modula za Python 3+ možete pronaći [ovdje](#).

Napomena: Na internetu možete pronaći puno dokumentacije i primjera korištenja poznatih modula; mi ćemo se fokusirati samo na neke od njih u nastavku ovog kolegija.

5.2 Paketi

Paketi (*eng. Packages*) su direktoriji koji sadrže **više modula**. Paketi su nam korisni kada želimo organizirati naš kod u logičke cjeline, gdje više različitih modula radi zajedno kako bi pružili određenu funkcionalnost.

Zamislite pakete kao foldere koji sadrže više Python skripti. Neke skripte (moduli) mogu biti povezane i zajedno čine funkcionalnu cjelinu (paket).

Primjer: Struktura paketa `faculty` koji sadrži module `studenti.py` i `operacije.py`:

```
faculty/ # direktorij paketa
|
├─ __init__.py
├─ studenti.py # modul 1
└─ operacije.py # modul 2
```

Uočite da za definiranje paketa moramo imati datoteku `__init__.py` u direktoriju paketa.

U `__init__.py` datoteci možemo definirati varijable, funkcije ili klase koje će biti dostupne prilikom učitavanja paketa, ali to **nije obavezno i ona može biti prazna**.

Idemo u modul `studenti.py` definirati klasu `Student` s atributima `ime`, `prezime` i `kolegiji` i metodama `pozdrav` i `kolegiji`:

```
# studenti.py

class Student:
    def __init__(self, ime, prezime, kolegiji):
        self.ime = ime
        self.prezime = prezime
        self.kolegiji = kolegiji

    def pozdrav(self):
        return f"Pozdrav, ja sam {self.ime} {self.prezime}."

    def ispis_kolegija(self):
        return f"Moji kolegiji su: {' '.join(self.kolegiji)}."
```

Koristimo sintaksu `from i import` za učitavanje **modula iz paketa**:

```
# main.py
from faculty import studenti

student_marko = studenti.Student("Marko", "Marković", ["Web aplikacije", "Raspodijeljeni
sustavi", "Operacijska istraživanja"])

print(student_marko.pozdrav()) # Pozdrav, ja sam Marko Marković.

print(student_marko.ispis_kolegija()) # Moji kolegiji su: Web aplikacije, Raspodijeljeni
sustavi, Operacijska istraživanja.
```

Unutar modula `operacije.py` možemo definirati neku funkciju koja će za svaki kolegij stvoriti rječnik gdje su ključevi kolegiji, a vrijednosti liste ocjena.

```
# operacije.py

def ocjene(kolegiji):
    return {kolegij: [] for kolegij in kolegiji}
```

Učitavanje modula `operacije.py`:

```
# main.py
from faculty import operacije

ocjene_studenta = operacije.ocjene(student_marko.kolegiji)

print(ocjene_studenta) # {'Web aplikacije': [], 'Raspodijeljeni sustavi': [], 'Operacijska
istraživanja': []}
```

- Možemo dodati funkciju koja simulira dodavanje 5 random ocjena studentu za od kolegija:

```
# operacije.py

import random

def simuliraj_ocjene(kolegiji):
    return {kolegij: [random.randint(1, 5) for _ in range(5)] for kolegij in kolegiji}
```

Učitavanje i korištenje funkcije:

```
# main.py
from faculty import studenti, operacije

student_marko = studenti.Student("Marko", "Marković", ["Web aplikacije", "Raspodijeljeni sustavi", "Operacijska istraživanja"])

ocjene_studenta = operacije.ocjene(student_marko.kolegiji)

print(ocjene_studenta) # {'Web aplikacije': [], 'Raspodijeljeni sustavi': [], 'Operacijska istraživanja': []}

simulacija_ocjena = operacije.simuliraj_ocjene(student_marko.kolegiji) # {'Web aplikacije': [2, 3, 1, 4, 4], 'Raspodijeljeni sustavi': [3, 1, 3, 4, 1], 'Operacijska istraživanja': [5, 2, 1, 1, 5]}

print(simulacija_ocjena)
```

Za ispis svih ocjena pojedinog studenta, možemo dodati novu metodu u klasu `Student` unutar modula `studenti.py`:

```
# studenti.py

class Student:
    def __init__(self, ime, prezime, kolegiji):
        self.ime = ime
        self.prezime = prezime
        self.kolegiji = kolegiji

    def pozdrav(self):
        return f"Pozdrav, ja sam {self.ime} {self.prezime}."

    def ispis_kolegija(self):
        return f"Moji kolegiji su: {' '.join(self.kolegiji)}."

    def ispis_ocjena(self, ocjene):
        for kolegij, ocjene in ocjene.items():
            print(f"Ocjene iz kolegija {kolegij}: {' '.join(map(str, ocjene))}.")
```

Ispis ocjena studenta:

```
student_marko.ispis_ocjena(simulacija_ocjena)

"""
Ocjene iz kolegija Web aplikacije: 5, 1, 1, 3, 4.
Ocjene iz kolegija Raspodijeljeni sustavi: 4, 4, 2, 5, 2.
Ocjene iz kolegija Operacijska istraživanja: 3, 3, 5, 4, 3.
"""
```

Naravno, postoji i mnoštvo ugrađenih paketa u Pythonu, a mi ćemo se fokusirati samo na neke od njih u nastavku ovog kolegija.

6. Zadaci za vježbu - Klase, objekti, moduli i paketi

Zadatak 4: Klase i objekti

- Definirajte klasu `Automobil` s atributima `marka`, `model`, `godina_proizvodnje` i `kilometraža`. Dodajte metodu `ispis` koja će ispisivati sve attribute automobila.
 - Stvorite objekt klase `Automobil` s proizvoljnim vrijednostima atributa i pozovite metodu `ispis`.
 - Dodajte novu metodu `starost` koja će ispisivati koliko je automobil star u godinama, trenutnu godine dohvatite pomoću `datetime` modula.
- Definirajte klasu `Kalkulator` s atributima `a` i `b`. Dodajte metode `zbroj`, `oduzimanje`, `mnozenje`, `dijeljenje`, `potenciranje` i `korijen` koje će izvršavati odgovarajuće operacije nad atributima `a` i `b`.
- Definirajte klasu `Student` s atributima `ime`, `prezime`, `godine` i `ocjene`.

Iterirajte kroz sljedeću listu studenata i za svakog studenta stvorite objekt klase `Student` i dodajte ga u novu listu `studenti_objekti`:

```
studenti = [
    {"ime": "Ivan", "prezime": "Ivić", "godine": 19, "ocjene": [5, 4, 3, 5, 2]},
    {"ime": "Marko", "prezime": "Marković", "godine": 22, "ocjene": [3, 4, 5, 2, 3]},
    {"ime": "Ana", "prezime": "Anić", "godine": 21, "ocjene": [5, 5, 5, 5, 5]},
    {"ime": "Petra", "prezime": "Petrić", "godine": 13, "ocjene": [2, 3, 2, 4, 3]},
    {"ime": "Iva", "prezime": "Ivić", "godine": 17, "ocjene": [4, 4, 4, 3, 5]},
    {"ime": "Mate", "prezime": "Matić", "godine": 18, "ocjene": [5, 5, 5, 5, 5]}
]
```

- Dodajte metodu `prosjek` koja će računati prosječnu ocjenu studenta.
 - U varijablu `najbolji_student` pohranite studenta s najvećim prosjekom ocjena iz liste `studenti_objekti`. Implementirajte u jednoj liniji koda.
- Definirajte klasu `Krug` s atributom `r`. Dodajte metode `opseg` i `povrsina` koje će računati opseg i površinu kruga.

- Stvorite objekt klase `Krug` s proizvoljnim radijusom i ispišite opseg i površinu kruga.

5. Definirajte klasu `Radnik` s atributima `ime`, `pozicija`, `placa`. Dodajte metodu `work` koja će ispisivati "Radim na poziciji {pozicija}".

- Dodajte klasu `Manager` koja nasljeđuje klasu `Radnik` i definirajte joj atribut `department`. Dodajte metodu `work` koja će ispisivati "Radim na poziciji {pozicija} u odjelu {department}".
- U klasu `Manager` dodajte metodu `give_raise` koja prima parametre `radnik` i `povecanje` i povećava plaću radnika (`Radnik`) za iznos `povecanje`.
- Definirajte jednu instancu klase `Radnik` i jednu instancu klase `Manager` i pozovite metode `work` i `give_raise`.

Zadatak 5: Moduli i paketi

Definirajte paket `shop` koji će sadržavati module `proizvodi.py` i `narudzbe.py`.

Modul `proizvodi.py`:

- definirajte klasu `Proizvod` s atributima `naziv`, `cijena` i `dostupna_kolicina`. Dodajte metodu `ispis` koja će ispisivati sve atribute proizvoda.
- u listu `skladiste` pohranite 2 objekta klase `Proizvod` s proizvoljnim vrijednostima atributa. U ovoj listi ćete pohranjivati instance klase `Proizvod` koje će predstavljati stanje proizvoda u skladištu.
- definirajte funkciju `dodaj_proizvod` van definicije klase koja će dodavati novi `Proizvod` u listu `skladiste`.

U `main.py` datoteci učitajte modul `proizvodi.py` iz paketa `shop` i pozovite pozovite funkciju `dodaj_proizvod` za svaki element iz sljedeće liste:

```
proizvodi_za_dodavanje = [  
    {"naziv": "Laptop", "cijena": 5000, "dostupna_kolicina": 10},  
    {"naziv": "Monitor", "cijena": 1000, "dostupna_kolicina": 20},  
    {"naziv": "Tipkovnica", "cijena": 200, "dostupna_kolicina": 50},  
    {"naziv": "Miš", "cijena": 100, "dostupna_kolicina": 100}  
]
```

Lista `skladiste` treba sada sadržavati ukupno 6 elemenata.

Nakon što to napravite, pozovite metodu `ispis` za svaki proizvod iz liste `skladiste`.

Modul `narudzbe.py`:

- definirajte klasu `Narudzba` s atributima: `naruceni_proizvodi` i `ukupna_cijena`.
- dodajte funkciju `napravi_narudzbu` van definicije klase koja prima listu proizvoda kao argument i vraća novu instancu klase `Narudzba`.
- dodajte provjeru u funkciju `napravi_narudzbu` koja će provjeravati dostupnost proizvoda prije nego što se napravi narudžba. Ako proizvoda nema na stanju, ispišite poruku: "Proizvod {naziv} nije dostupan!" i ne stvarajte narudžbu.
- dodajte provjere u funkciju `napravi_narudzbu` koja će provjeriti sljedeća 4 uvjeta:
 - argument `naruceni_proizvodi` mora biti lista
 - svaki element u listi mora biti rječnik
 - svaki rječnik mora sadržavati ključeve `naziv`, `cijena` i `narucena_kolicina`

- lista ne smije biti prazna
- izračunajte ukupnu cijenu narudžbe koju ćete pohraniti u lokalnu varijablu `ukupna_cijena` u jednoj liniji koda.
- narudžbe (instanca klase `Narudzba`) pohranite u listu rječnika `narudzbe`.
- u klasu `Narudzba` dodajte metodu `ispis_narudzbe` koja će ispisivati nazive svih naručenih proizvoda, količine te ukupnu cijenu narudžbe.
 - npr. "Naručeni proizvodi: Laptop x 2, Monitor x 1, Ukupna cijena: 11000 eur".

U `main.py` datoteci učitajte modul `narudzbe.py` iz paketa `shop` i pozovite funkciju `napravi_narudzbu` s listom proizvoda iz prethodnog zadatka.